Модуль: AI Analyst и ассистент

1. Назначение и границы

Отвечает на вопросы по данным через инструменты (tools), а не прямым доступом к базе: backend/app/ai/tools/{analytics,customers,scenarios,actions}.py. Провайдер модели — заменяемый (ai/providers/base.py, реализации ollama.py, mock.py). Не делает: не исполняет произвольный SQL, не ходит в данные в обход инструментов, не работает при AEZA_AI_ENABLED=0.

2. Сценарии использования

- Вопрос «какие услуги под риском» → вызов инструмента → ответ с цифрами и источниками.
- Ответ без модели (mock-провайдер) в тестах и при отключённом AI.
- Отказ: провайдер недоступен → внятная ошибка, обычные расчёты продолжают работать.

3. Контракт

/api/v1/ai/*, /api/v1/model/* в backend/openapi.json. Внутренний контракт — ai/service.py и схемы ai/schemas.py; инструменты объявляют вход/выход явно.

4. Данные

Собственных таблиц нет: чтение идёт через инструменты, которые вызывают домен аналитики. Ответы не сохраняются как источник истины — цифры всегда берутся из домена.

5. Права

Требуется аутентификация; инструменты доступны только в рамках роли аналитика. Проверки безопасности входа/выхода — ai/safety.py (экранирование, ограничения контекста).

6. Зависимости

Исходящие: домен аналитики, провайдер LLM по HTTP, RAG-индекс (ai/rag/index.py). Входящие: backend/app/api/routes_ai.py.

7. Конфигурация

AEZA_AI_ENABLED, AEZA_AI_PROVIDER, AEZA_AI_MODEL, AEZA_AI_BASE_URL, AEZA_AI_MAX_TOKENS, AEZA_AI_TIMEOUT_SECONDS, AEZA_LLM_*, AEZA_OLLAMA_*. Выключено по умолчанию: AI — опция, а не условие работы продукта.

8. Сборка и отладка

```
python -m pytest backend/tests/test_ai.py -q
python -m backend.app.ai.rag --docs ./docs --out backend/data/rag_index.json
```

9. Тесты

`backend/tests/test_ai.py`: вызов инструментов, отключённый режим, mock-провайдер, защита от небезопасного вывода. Проверка «AI не становится источником истины» — цифры в ответах совпадают с доменом.

10. Наблюдаемость

Состояние провайдера видно через `/api/v1/model/*`; ошибки провайдера логируются без содержимого промптов. Метрики задержек — `/metrics`; таймаут по умолчанию 420 с заметен оператору как долгие запросы.

11. Ограничения и готовность

- Качество ответа не гарантируется; компенсируется тем, что цифры берутся из домена.
- RAG-индекс собирается в образ при сборке — после изменения `docs/` нужна пересборка.
- Готовность: при выключенном AI продукт полностью работоспособен; инструменты не дают доступа к данным, недоступным пользователю.